

SISTEMA DE PREDICCIÓN DE RIESGO DE DIABETES

con XGBoost y Explicabilidad SHAP

ML Clásico Avanzado · SHAP · Streamlit · Python · Power BI

Autor	Bryan Anthony López Guerrero
Formación	Ing. TI Máster Visual Analytics y Big Data Esp. Big Data e IA
Dataset	Pima Indians Diabetes — UCI ML Repository (768 pacientes)
Modelo	XGBoost + SMOTE + Optimización de hiperparámetros
Explicabilidad	SHAP — SHapley Additive exPlanations
Herramientas	Python · XGBoost · SHAP · Streamlit · Power BI
Fecha	Abril 2026

Resumen ejecutivo

Este proyecto desarrolla un sistema de predicción de riesgo de diabetes aplicando XGBoost sobre el dataset Pima Indians Diabetes (UCI, 768 pacientes, 8 variables clínicas). El modelo alcanzó un ROC-AUC de 0.8900 y F1=0.7475, superando a Regresión Logística (0.8626) y Random Forest (0.8601). Se aplicó SMOTE para el desbalance de clases y SHAP para explicar cada predicción. La glucosa emerge como predictor más importante (SHAP=1.3447). El proyecto culmina con una app Streamlit interactiva.

1. Introducción y Contexto

La diabetes mellitus afecta a más de 537 millones de adultos a nivel mundial (IDF, 2021). Su diagnóstico tardío genera complicaciones graves y costos sanitarios elevados. El Machine Learning ofrece herramientas para la detección temprana de riesgo, permitiendo intervenciones preventivas antes del desarrollo de la enfermedad.

El mayor obstáculo para adoptar ML en entornos clínicos es la falta de interpretabilidad. Los médicos necesitan entender por qué el modelo toma una decisión. Este proyecto aborda ese problema con SHAP, que proporciona explicaciones matemáticamente rigurosas para cada predicción individual.

1.1 Preguntas de investigación

1. ¿Qué variables clínicas predicen mejor el riesgo de diabetes?
2. ¿Puede XGBoost superar el 85% de ROC-AUC en este dataset?
3. ¿Cómo afecta el desbalance de clases y cómo se corrige con SMOTE?
4. ¿Qué variables influyen más en pacientes individuales según SHAP?
5. ¿Es posible construir una herramienta clínica interpretable y usable?

1.2 Hipótesis

1. H1: La glucosa es la variable más importante para predecir diabetes.
2. H2: SMOTE mejora significativamente el recall de la clase positiva.
3. H3: XGBoost supera a Regresión Logística y Random Forest en ROC-AUC.
4. H4: SHAP revela interacciones entre glucosa y BMI clínicamente validadas.

2. Datos y Metodología

2.1 Dataset

El dataset Pima Indians Diabetes (UCI) contiene información clínica de 768 mujeres de herencia indígena Pima, grupo con alta prevalencia de diabetes tipo 2. El 34.9% de casos corresponde a la clase positiva, generando un desbalance moderado que requiere tratamiento específico.

Variable	Descripción	Rango
Pregnancies	Número de embarazos	0–17
Glucose	Glucosa en plasma (mg/dL)	44–199
BloodPressure	Presión arterial diastólica (mm Hg)	24–122
SkinThickness	Grosor pliegue cutáneo (mm)	0–99
Insulin	Insulina sérica a 2h (mu U/ml)	0–846
BMI	Índice de masa corporal (kg/m²)	0–67
DiabetesPedigreeFunction	Función de pedigrí familiar	0.08–2.42
Age	Edad (años)	21–81
Outcome	Diagnóstico de diabetes (0/1)	0–1

Tabla 1. Variables del dataset Pima Indians Diabetes.

2.2 Valores cero imposibles e imputación

Cinco variables contienen ceros clínicamente imposibles (glucosa=0, presión=0, BMI=0) que representan datos faltantes. Fueron imputados con la mediana por clase para preservar la distribución diferencial entre pacientes diabéticos y no diabéticos.




Figura 1. Porcentaje de ceros por variable. Fuente: elaboración propia.

2.3 Pipeline de preprocesamiento

Etap	Descripción	Herramienta
1. Imputación	Mediana por clase para ceros imposibles	pandas
2. Split estratificado	80% train / 20% test preservando clases	sklearn

Etapa	Descripción	Herramienta
3. Scaling	Estandarización $\mu=0$, $\sigma=1$	StandardScaler
4. SMOTE	Sobremuestreo sintético clase minoritaria	imbalanced-learn
5. XGBoost	Entrenamiento con hiperparámetros optimizados	xgboost
6. SHAP	Explicabilidad global e individual	shap

Tabla 2. Pipeline del proyecto.

3. Análisis Exploratorio de Datos

La glucosa muestra la separación más pronunciada entre clases: 142 mg/dL promedio para diabéticos vs 110 mg/dL para no diabéticos. El BMI también difiere significativamente (35 vs 30 kg/m²), consistente con la relación entre obesidad y diabetes tipo 2.




Figura 2. Distribución de variables clínicas por clase. Fuente: elaboración propia.




Figura 3. Boxplots por clase. Fuente: elaboración propia.




Figura 4. Matriz de correlaciones. Fuente: elaboración propia.

Hallazgo 1

La glucosa tiene la mayor correlación con el Outcome ($r=0.47$). El 34.9% de casos positivos requiere SMOTE para evitar sesgo del modelo hacia la clase mayoritaria.

4. Modelo XGBoost y Resultados

Se evaluaron tres modelos. XGBoost superó a ambos baselines. La validación cruzada confirma estabilidad: CV ROC-AUC=0.9383 ± 0.0070.




Figura 5. Comparación de modelos — Curvas ROC. Fuente: elaboración propia.

Modelo	ROC-AUC	F1-Score	Seleccionado
Logistic Regression	0.8626	—	No
Random Forest	0.8601	—	No
XGBoost	0.8900	0.7475	✓ Sí

Tabla 3. Comparación de modelos.

Clase	Precision	Recall	F1-Score	Support
Sin diabetes (0)	0.844	0.920	0.880	100
Con diabetes (1)	0.822	0.685	0.747	54
ROC-AUC / CV	0.890	0.938	—	154

Tabla 4. Métricas del modelo XGBoost.




Figura 6. Diagnóstico del modelo. Fuente: elaboración propia.

Hallazgo
2

XGBoost: ROC-AUC=0.8900, F1=0.7475. Supera a LR (0.8626) y RF (0.8601). SMOTE balanceó 400/214 → 400/400 mejorando el recall de la clase positiva al 69%.

5. Explicabilidad con SHAP

SHAP asigna a cada variable una contribución justa a la predicción, basada en la teoría de juegos cooperativos. A diferencia de la importancia por ganancia de XGBoost, SHAP tiene garantías matemáticas de consistencia: la suma de valores SHAP más el valor base es exactamente igual a la predicción del modelo.

5.1 Importancia global

La glucosa es la variable más importante (SHAP=1.3447), seguida de insulina (1.3006) y edad (0.6715). Esto valida que el modelo aprendió relaciones clínicamente significativas.




Figura 7. SHAP Summary Plot. Fuente: elaboración propia.




Figura 8. Importancia global SHAP. Fuente: elaboración propia.

5.2 Explicación individual

Los Waterfall plots muestran cómo cada variable empuja la predicción hacia o contra el riesgo para un paciente específico. Barras rojas aumentan el riesgo, verdes lo reducen.




Figura 9. SHAP Waterfall — 3 perfiles de pacientes. Fuente: elaboración propia.




Figura 10. SHAP Dependence Plots. Fuente: elaboración propia.

Hallazgo
3

Glucosa: variable más importante (SHAP=1.3447). Los Dependence Plots confirman que el riesgo se dispara cuando glucosa alta coincide con BMI elevado — interacción clínicamente validada.

6. Conclusiones y Aplicación

6.1 Conclusiones

- 1. XGBoost supera a los baselines.** ROC-AUC=0.8900, validación cruzada estable (0.9383 ± 0.0070).
- 2. Glucosa e insulina dominan la predicción.** Consistente con el conocimiento clínico, validando que el modelo aprendió relaciones significativas y no espurias.
- 3. SMOTE mejora el recall.** El modelo detecta el 69% de pacientes diabéticos reales, crítico en contexto clínico donde los falsos negativos son graves.
- 4. SHAP convierte el modelo en herramienta clínica.** La explicabilidad individual facilita la adopción en entornos reales donde médicos y pacientes necesitan entender las predicciones.

6.2 App Streamlit

El proyecto incluye una aplicación web interactiva en Streamlit donde el usuario ingresa sus indicadores clínicos y recibe en tiempo real: probabilidad de riesgo, clasificación y explicación SHAP visual. Esto transforma el modelo de notebook académico a producto usable.

6.3 Recomendaciones

#	Recomendación	Impacto
1	Escalar con datos reales de hospitales para adaptar al contexto local	Alto
2	Añadir variables de estilo de vida para mejorar poder predictivo	Alto
3	Implementar monitoreo de drift del modelo en producción	Medio
4	Explorar modelos de series temporales para múltiples mediciones	Medio

Tabla 5. Recomendaciones para trabajo futuro.

Hallazgo 4	El sistema combina precisión (ROC-AUC=0.89), explicabilidad (SHAP) y usabilidad (Streamlit). Esta combinación es exactamente lo que las empresas buscan al llevar ML a producción.
---------------	--

7. Referencias

- [1] Smith et al. (1988). Using the ADAP learning algorithm to forecast onset of diabetes. *Proceedings Annual Symposium Computer Application in Medical Care*, 261–265.
- [2] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *ACM SIGKDD*, 785–794. <https://doi.org/10.1145/2939672.2939785>
- [3] Lundberg, S.M., & Lee, S.I. (2017). A unified approach to interpreting model predictions. *NeurIPS* 30. <https://arxiv.org/abs/1705.07874>
- [4] Chawla, N.V. et al. (2002). SMOTE: Synthetic minority over-sampling technique. *JAIR*, 16, 321–357.
- [5] Pedregosa, F. et al. (2011). Scikit-learn: Machine learning in Python. *JMLR*, 12, 2825–2830.
- [6] International Diabetes Federation. (2021). *IDF Diabetes Atlas, 10th ed.*